

Informe de predicción de anomalías en transacciones

Alcance

Generar un modelo, usando algoritmos de Machine Learning, el cual permita identificar transacciones fraudulentas, disminuyendo los costos asociados y aumentando la confianza de nuestros clientes hacia la institución

Descripción del problema

La identificación de anomalías en transacciones es fundamental para evitar el descontento de los clientes, evitar daños en la reputación y el ahorro de costos debido al extorno de la suma total o parcial de las anomalías.

Actualmente, no se cuenta con ninguna forma de evitar frenar las transacciones fraudulentas antes de que el cliente se diera cuenta y notificara, haciendo que sienta poca seguridad hacia la empresa y provocando abandono de los productos que maneja en esta entidad. Por lo cual, se debe realizar la implementación de algún modelo que permita reconocer las anomalías en transacciones con el fin de minimizar cualquier tipo de pérdida que estas puedan generar.

Descripción de los datos

Los datos con los que se entrenó el modelo consistían en un histórico de las 30 transacciones más recientes de cada cliente. Para cada transacción se contaba con el monto, la fecha y hora y el tipo de establecimiento en el que fue registrada la transacción. Además, cada cliente contaba con la proporción histórica de los tipos de negocios en los que han hecho transacciones.

El conjunto de datos utilizados contaba con 100,000 datos, de los cuales 89,936 eran transacciones normales, 3,994 eran de anomalías debido al orden no congruente, 3,611 eran de anomalías debido a transacciones cortas (muchas transacciones en poco tiempo) y 2,459 eran anomalías debido a compras en establecimientos no comunes para el cliente. Los datos solo fueron separados por clientes, debido a que se decidió entrenar los modelos usando las 30 transacciones de cada cliente. Prevenimos la fuga de datos separando algunos clientes, del conjunto de entrenamiento. Se aseguró de que tuvieran aproximadamente la misma proporción de anomalías.

Modelos generados

Modelo A: Línea base sin orden

Para este modelo se generó un modelo usando Random Forest, el cual se entrenó únicamente con las siguientes variables agregadas: promedio, desviación estándar, máximo y mínimo de los montos, el monto por hora, la moda del establecimiento y la cantidad de tipos de establecimientos.

Modelo B: Modelo secuencial

Para este modelo se generó una red LSTM, la cual fue entrenada con los montos de las últimas 30 transacciones del cliente. Se usó LSTM debido a que permite mejor precisión que otros modelos recurrentes, pero a pesar del costo computacional que puede tener puede ser compensado con el ahorro generado por las correctas predicciones.

Modelo C: Apuesta del equipo

Un modelo que implementa:

- Una red CNN-1D para identificar las anomalías de transacciones cortas.
- Una red LSTM para identificar aquellas anomalías en el orden de los montos de las transacciones.
- Random Forest que permite identificar las anomalías por tipo de negocio.

Se cree que esta combinación de modelos mejorará la predicción de las anomalías, debido a que cada submodelo estará especializado en un tipo de anomalía porque es más específico y aprende a reconocer los patrones que surgen de las anomalías consideradas.

Resultados iniciales de los modelos (umbral 0.5)

Cuadro 1: Métricas por etiqueta del modelo A, respecto al conjunto de prueba.

Etiqueta	Precision	Recall	F1-score
No anomalía	0.92	0.97	0.94
Anomalía	0.43	0.22	0.29

Cuadro 2: Métricas generales del modelo A, respecto al conjunto de prueba (se toma la etiqueta anomalía como positiva).

Métrica	Valor
PR-AUC	0.3104
Accuracy	0.89
Verdaderos negativos	17,411
Verdaderos positivos	435
Falsos negativos	1,578
Falsos positivos	576

Cuadro 3: Métricas por etiqueta del modelo B, respecto al conjunto de prueba.

Etiqueta	Precision	Recall	F1-score
No anomalía	0.93	0.97	0.95
Anomalía	0.62	0.91	0.48

Cuadro 4: Métricas generales del modelo B, respecto al conjunto de prueba (se toma la etiqueta anomalía como positiva).

Métrica	Valor
PR-AUC	0.4706
Accuracy	0.91
Verdaderos negativos	17,507
Verdaderos positivos	787
Falsos negativos	1,226
Falsos positivos	480

Cuadro 5: Métricas por etiqueta del modelo C, respecto al conjunto de prueba.

Etiqueta	Precision	Recall	F1-score
No anomalía	0.99	0.94	0.97
Anomalía	0.66	0.94	0.77

Cuadro 6: Métricas generales del modelo C, respecto al conjunto de prueba (se toma la etiqueta anomalía como positiva).

Métrica	Valor
PR-AUC	0.9076
Accuracy	0.94
Verdaderos negativos	16,997

Verdaderos positivos	1,889
Falsos negativos	124
Falsos positivos	990

Análisis de umbral y económico

Para el siguiente análisis se tomó en cuenta el costo de predecir incorrectamente anomalías y no anomalías. No detener una transacción fraudulenta incurrirá en un costo promedio de Q 4,200 y el caso de detener una transacción legítima es Q 180.

Cuadro 7: Umbrales óptimos e implicaciones económicas en el conjunto de entrenamiento.

Modelo	Umbral óptimo	Costo por transacción
A	0.4440	Q 4.09
B	0.2937	Q 161.68
C	0.4789	Q 13.87

Cuadro 8: Errores y costos de los modelos en el conjunto de prueba, aplicando umbral óptimo.

Modelo	Verdadero negativo	Verdaderos positivos	Falsos negativos	Falsos positivos	Costo por transacción
A	16,996	566	1,447	991	Q 312.79
B	119	2,009	4	17,868	Q 161.65
C	16,848	1,904	109	1,139	Q 33.14

Principales riesgos en los modelos

En la siguiente sección se mostrarán dos experimentos realizados, uno en el modelo B y otro en el C, que muestra posibles problemas que pueden experimentar los modelos.

Primer experimento

El primer experimento se ha realizado sobre el modelo B. Este ha consistido en la permutación de la secuencia de datos que el modelo había de procesar y evaluar su capacidad predictiva comparándolo con el modelo original. El siguiente cuadro muestran tanto los resultados, como su comparación con los resultados del modelo original.

Cuadro 9. Comparación de métricas del modelo con datos permutados respecto a los datos originales.

Modelo	Precision	Recall	F1	Accuracy	PR-AUC
LSTM ordenada	0.62	0.91	0.48	0.91	0.4706
LSTM permutada	0.10	0.99	0.18	0.11	0.1039
Diferencia	0.52	-0.08	0.30	0.80	0.3667

Segundo experimento

Este experimento se realizó sobre el modelo C, el cual consistió en silenciar submodelos y observar cuánto disminuía la capacidad predictiva del modelo. Los siguientes dos cuadros muestran los resultados de este experimento.

Cuadro 10: Errores de silenciamiento de submodelos.

Submodelos usados	Verdadero negativo	Verdadero positivo	Falso negativo	Falso positivo
Todos	16,848	1,904	109	1,139
CNN-1D	17,892	728	1,285	95
LSTM	17,564	802	1,211	423
Random Forest	17,349	456	1,557	638
CNN-1D y LSTM	17,470	1,514	499	517
CNN-1D y Random Forest	17,256	1,155	858	731
LSTM y Random Forest	16,940	1,221	792	1,047

Cuadro 11: Promedio de etiqueta en el silenciamiento de modelos y por tipo de anomalía (0 no anomalía y 1 anomalía).

Submodelos usados	Normal	Establecimiento raro	Orden no congruente	Transacción corta
Todos	0.0633	0.8150	0.9787	0.9986
CNN-1D	0.0053	0.0020	0.0075	0.9986
LSTM	0.0235	0.0224	0.9775	0.0139
Random Forest	0.0356	0.8110	0.0363	0.0388
CNN-1D y LSTM	0.0287	0.0244	0.9774	0.9986
CNN-1D y Random Forest	0.0406	0.8110	0.0438	0.9986
LSTM y Random Forest	0.0582	0.8150	0.9787	0.0526

Conclusiones y recomendaciones

El modelo A no presentó buenos resultados en los modelos preliminares con umbral de 0.5, teniendo muchas dificultades para predecir las anomalías. Mostró el menor costo en el ajuste de umbral (Q 4.09 por transacción), con el conjunto de entrenamiento, pero esto fue debido a un sobreajuste en el modelo, ya que al aplicarlo al conjunto de prueba se tuvo un costo de Q 312.79 por transacción, el cual fue el mayor de todos.

El modelo B ha presentado dificultades para predecir anomalías correctamente. Esto debido a que existen distintos tipos de anomalías, las cuales no dependen del orden de las transacciones, como lo son los tipos de establecimiento y las transacciones cortas. Mostró el segundo mayor costo de umbral (Q 161.68 por transacción), así como el segundo mayor costo en el conjunto de prueba (Q 161.65 por transacción).

El modelo B se ve muy afectado si el orden de las transacciones es distinto (véase Primer experimento). En el cuadro 9 puede observarse que realizar las permutaciones a los montos disminuyó todas las métricas, a excepción del recall. Esto se debe a que el modelo B está entrenado para reconocer patrones de orden, por lo que, si el orden de las transacciones es distinto, el modelo puede predecir incorrectamente las transacciones anómalas.

El modelo C presentó buenos resultados para la predicción de anomalías y no anomalías. Mostró el segundo menor costo en el ajuste de umbral (Q 13.87 por transacción), con el conjunto de entrenamiento, y al aplicarlo al conjunto de prueba se tuvo un costo de Q 33.14 por transacción, el cual fue el menor de todos con diferencia. Además, con la prueba realizada (véase Segundo experimento), se concluye que es más eficiente entrenar distintos submodelos enfocados a reconocer un tipo de anomalía específica (véase cuadro 10 y 11).

Se recomienda hacer uso del modelo C para la predicción de anomalías y no anomalías. Además, si en el futuro se reconocen otro tipo de anomalías o se agrega nueva información, se deben reentrenar los modelos para mejorar la capacidad predictiva y así evitar las transacciones fraudulentas.

Anexo

Cuadro 12: Evidencias.

Evidencia	Cuadro	Donde aparece	Conclusión	Limitación
El costo por error es el menor de los tres modelos y considerando que este modelo tiene menos falsos positivos y negativos que el modelo A, y más verdaderos positivos y verdaderos negativos, parece ser la mejor opción de los tres.	7 y 8	En el costo de entrenamiento y los costos totales. Asimismo, se puede observar en la cantidad de verdaderos y falsos, tanto positivos como negativos.	Para el umbral optimizado, el modelo C es el mejor modelo.	El costo de entrenamiento es el segundo mayor de los tres modelos optimizados respecto al umbral.
Considerando lo dicho anteriormente respecto al modelo C, este ha resultado ser el umbral óptimo si se eligiese este. Agregado a ello, el que sea el umbral de mayor valor entre los tres modelos hace que el modelo sea más restrictivo en cuanto a la elección hecha, lo que se puede observar en los resultados que este modelo optimizado brinda.	7	Se observa en la columna correspondiente a los umbrales óptimos.	El umbral óptimo por aplicar es 0.4789 correspondiente al modelo C.	Su uso depende de que el punto anterior se cumpla.
Se observa que la diferencia de valores en el cuadro 10 muestra que, aunque el cambio es mayor en Recall que en las otras métricas consideradas en ese cuadro. Asimismo, se observa en los valores correspondientes del cuadro 9 a las métricas PR-AUC.	9	Se observa en la diferencia de los valores de las métricas en las tablas mencionadas.	El orden en que el modelo B (LSTM) recibe los datos influencia el resultado de este.	La sensibilidad del modelo a los datos, ya que el orden en que este los reciba cambiará el resultado del experimento, por lo que, si no se le dan exactamente las mismas condiciones, el resultado podría diferir de este.
se evidencia que el modelo se ve particularmente afectado para la identificación de falsos positivos y falsos negativos cuando están en uso los submodelos CNN-1D, LSTM y Random Forest, de manera individual.	10 y 11	Se observa principalmente en los cambios de los valores de falso positivo y falso negativo del Cuadro 11.	El silenciamiento de ciertos submodelos del modelo C afecta la capacidad predictiva del mismo.	El uso de redes neuronales lo hace un modelo sensible a los datos, como ha sido demostrado en el punto anterior.