




Predicción de anomalías

IAN CASTELLANOS

RICARDO RODRÍGUEZ




Generador de datos

- 3 Tipos de anomalías: Orden no congruente, transacción corta y establecimientos extraños.
- 30 transacciones.
- Montos, fecha-hora, tipo de establecimiento y proporción histórica de tipo de establecimiento.
- Proporción anomalías aproximadamente 10%.
- Variables agregadas: promedio, desviación estándar, máximo y mínimo de los montos, monto por hora, moda de tipo de establecimiento y la cantidad de establecimientos.

Modelos iniciales y preprocesamiento


Modelo A: Random Forest

- Variables agregadas
- Tratamiento variables categóricas.
- Rejilla de hiperparámetros.
- Validación cruzada.
- Peso de clases



Modelo B: LSTM

- Montos.
- Escala log.
- Estandarización
- Peso de clases



Modelos apuesta (C)

CNN-1D


- Diferencia en minutos de las transacciones.
- Escala log.
- Estandarización.
- Red con 2 capas ocultas.

LSTM

- Montos.
- Escala log.
- Estandarización
- Categóricas.
- Red con 2 capas ocultas.

Random Forest


- Tipos de establecimiento.
- Histórico de tipos de establecimiento
- Proporciones de tipos de establecimiento.
- Diferencias absolutas entre proporciones e histórico.
- Rejilla de hiperparámetros.
- Validación cruzada.
- Peso de clases



Análisis de umbral


Modelo A

- Umbral óptimo: 0.4440
- Costo por transacción (en entrenamiento): Q 4.09
- Costo por transacción (en prueba): Q 312.79




Modelo B

- Umbral óptimo: 0.2937
- Costo por transacción (en entrenamiento): Q 161.68
- Costo por transacción (en prueba): Q 161.65



Modelo C

- Umbral óptimo: 0.4789
- Costo por transacción (en entrenamiento): Q 13.87
- Costo por transacción (en prueba): Q 33.14



Pruebas a los modelos (Prueba 1)

Modelo	Precision	Recall	F1	Accuracy	PR-AUC
LSTM ordenada	0.62	0.91	0.48	0.91	0.4706
LSTM permutada	0.10	0.99	0.18	0.11	0.1039
Diferencia	0.52	-0.08	0.30	0.80	0.3667

Pruebas a los modelos (Prueba 2)

CAPACIDAD PREDICTIVA

Submodelos usados	Verdadero negativo	Verdadero positivo	Falso negativo	Falso positivo
Todos	16,848	1,904	109	1,139
CNN-1D	17,892	728	1,285	95
LSTM	17,564	802	1,211	423
Random Forest	17,349	456	1,557	638
CNN-1D y LSTM	17,470	1,514	499	517
CNN-1D y Random Forest	17,256	1,155	858	731
LSTM y Random Forest	16,940	1,221	792	1,047

PROMEDIO DE ETIQUETAS

Submodelos usados	Normal	Establecimiento raro	Orden no congruente	Transacción corta
Todos	0.0633	0.8150	0.9787	0.9986
CNN-1D	0.0053	0.0020	0.0075	0.9986
LSTM	0.0235	0.0224	0.9775	0.0139
Random Forest	0.0356	0.8110	0.0363	0.0388
CNN-1D y LSTM	0.0287	0.0244	0.9774	0.9986
CNN-1D y Random Forest	0.0406	0.8110	0.0438	0.9986
LSTM y Random Forest	0.0582	0.8150	0.9787	0.0526

Conclusiones y Recomendaciones

- El modelo A tuvo el menor costo en el ajuste de umbral, pero esto fue debido a un sobreajuste en el modelo, ya que en el conjunto de prueba fue el más alto en costo por transacción.
- El modelo B tuvo el mayor costo en el ajuste de umbral y al aplicarlo al conjunto de prueba se tuvo un costo de Q 161.65 por transacción, el cual fue el segundo menor de todos.
- El modelo C tuvo el segundo menor costo en el ajuste de umbral y al aplicarlo al conjunto de prueba se tuvo un costo de Q 33.14 por transacción, el cual fue el menor de todos con diferencia.
- El cambio del orden en los montos afectó la capacidad predictiva del modelo B, disminuyendo todas sus métricas a excepción del recall que aumentó.
- Se concluye que es más eficiente entrenar distintos submodelos enfocados a reconocer un tipo de anomalía específica.
- Se recomienda hacer uso del modelo C para la predicción de anomalías y no anomalías..